

Δημιουργία RAG αρχιτεκτονικής για ερωτήσεις φυσικής γλώσσας σε ειδησεογραφικά άρθρα

ΜΥΕΟΟ3-ΑΝΑΚΤΗΣΗ ΠΛΗΡΟΦΟΡΙΑΣ ΑΘΑΝΑΣΙΟΣ ΤΟΝΙΟΣ ΑΜ:4933, ΠΑΝΑΓΙΩΤΗΣ ΤΡΥΠΟΣ ΑΜ:5131

Περιεχόμενα

Εισαγωγή	2
Λοποίηση	3
rag_data_preparation	
query_engine.py	5
gui_app.py	7
Ιειραματικές δοκιμές	g

Github Repository:

https://github.com/ThePhantom2307/MYE003-Articles-SearchEngine

Εισαγωγή

Στην παρούσα εργασία θα υλοποιήσουμε την κατασκευή μιας RAG αρχιτεκτονικής που θα μας επιτρέψει να απαντάμε ερωτήσεις σχετικά ειδησεογραφικά άρθρα. Τα άρθρα που θα χρησιμοποιηθούν για το augmented κομμάτι της υλοποίησης, προέρχονται από το CNN, είναι δημοσιευμένα κατά την περίοδο 2011 έως 2022 και καλύπτουν ένα ευρύ φάσμα δημοσιογραφικών θεμάτων.

Η RAG αρχιτεκτονική έχει στόχο την βελτίωση των απαντήσεων που παράγει ένα LLM. Αυτό γίνεται αρχικά από την ανάκτηση των πληροφοριών που κάνει πχ στην δικιά μας περίπτωση από το .csv αρχείο που περιέχει τα άρθρα. Στη συνέχεια δίνονται ως ενίσχυση στο LLM όπου και τελικά θα παράγει την απάντηση του χρησιμοποιώντας τόσο την ερώτηση του χρήστη όσο και τις ανακτημένες πληροφορίες.

Στη έκταση της παρούσας αναφοράς θα περιγράψουμε την υλοποίηση μας για την RAG αρχιτεκτονική καθώς και θα εμβαθύνουμε σχετικά με τις βιβλιοθήκες και τις συναρτήσεις αυτών που χρησιμοποιήσαμε. Τέλος θα παραθέσουμε τα μερικά πειραματικά queries μαζί με τα αποτελέσματα τους και θα τα συγκρίνουμε με και χωρίς context.

Υλοποίηση

Για την υλοποίηση της εργασίας έχουμε χωρίσει το source code σε τρία μέρη (modular σχεδίαση) καθώς θεωρήσαμε ότι θα είναι πιο εύκολο στην κατανόηση ενός τρίτου αλλά και για λόγους επεκτασιμότητας ή συντήρησης στο μέλλον. Τα μέρη που το αποτελούν είναι το rag_data_preparation.py το οποίο είναι υπεύθυνο για το preprocessing των αρχείων, το query_engine.py το οποίο παίρνει τα chunks που έχουν παραχθεί, κατασκευάζει το query καθώς και το response του μοντέλου το οποίο και καλεί. Τέλος, το τρίτο μέρος αποτελεί την υλοποίηση ενός απλού gui περιβάλλοντος για την ευκολότερη χρήση της μηχανής.

rag data preparation

Σε αυτό το μέρος θα αναλύσουμε το preprocessing που θα κάνουμε στο αρχείο CNN_Articels_clean για να μπορέσουμε κάνουμε extract τα άρθρα από αυτό και να τα χρησιμοποιήσουμε αργότερα ως context στο LLM.

Δημιουργούμε το αρχείο rag_data_preparation.py και κάνουμε import όλες τις βιβλιοθήκες που θα γρησιμοποιήσουμε στην συνέχεια.

```
import os
import torch
import pandas as pd
import numpy as np
import faiss
from sentence_transformers import SentenceTransformer
from langchain.text_splitter import RecursiveCharacterTextSplitter
```

Έπειτα θέτουμε ως σταθερές τα ονόματα των αρχείων που θα δημιουργηθούν, δηλαδή το index τύπου .faiss, το .csv που θα περιέχει τα chunks των άρθρων και το .csv από το οποίο θα εξάγουμε τα chunks.

```
INDEX_FILE = "articles_index.faiss"
CHUNKS_FILE = "chunk_metadata.csv"
CSV_FILE = "CNN_Articels_clean.csv"
```

Όλο το preprocessing γίνεται με την συνάρτηση generate_faiss_and_chunks(). Αρχικά, ελέγχουμε αν έχει ήδη παραχθεί το index file και το chunk file. Αυτός ο έλεγχος γίνεται ώστε ο χρήστης να μη χρειάζεται να δημιουργεί κάθε φορά τα αρχεία αυτά, καθώς ανάλογα με το hardware του (όπως θα δούμε και παρακάτω) μπορεί να πάρει αρκετή ώρα για την δημιουργία τους. Στη συνέχεια διαβάζουμε το αρχείο με τα άρθρα και το κρατάμε σε ένα dataframe με χρήση της βιβλιοθήκης pandas. Έπειτα, από το dataframe κρατάμε μόνο το πεδίο που περιέχει τα κείμενα των άρθρων (df["Article text"]) στην μεταβλητή articles και τα μετατρέπουμε σε λίστα.

```
def generate_faiss_and_chunks():
    if os.path.exists(INDEX_FILE) and os.path.exists(CHUNKS_FILE): #Tsekaroume an yparxoun hdh
        return

df = pd.read_csv(CSV_FILE) #Diavazoume to CSV
    articles = df["Article text"].dropna().tolist() #Kratame to pedio Article text gia na paroume ta arthra
    text_splitter = RecursiveCharacterTextSplitter(chunk_size=500, chunk_overlap=100)
```

Συνεχίζοντας, ορίζουμε chucker/text splitter. Στη υλοποίηση μας αποφασίσαμε να χρησιμοποιήσουμε τον RecursiveCharacterTextSplitter από την βιβλιοθήκη LangChain. Ο λόγος που χρησιμοποιήσαμε αυτόν και όχι τον SemanticChunker είναι επειδή με τον RecursiveCharacterTextSplitter ορίσουμε εμείς το chunk size καθώς και το chunk overlap. Συγκεκριμένα, το chunk_size=500 δηλώνει ότι κάθε chunk θα είναι 500 χαρακτήρων και το chunk_overlap=100 που σημαίνει ότι κάθε chunk επικαλύπτεται με το προηγούμενο κατά 100 χαρακτήρες. Αυτό βοηθάει στο να μη χάνεται το νόημα όταν σπάμε στο κείμενο σε chunks.

Επειτα, δημιουργούμε μια λίστα όπου σε αυτή θα κρατάμε τα chunks και διατρέχουμε όλα τα άρθρα. Για κάθε άρθρο χρησιμοποιούμε τη συνάρτηση split_text η οποία καλείται από τον splitter που έχουμε ορίσει, δηλαδή τον RecursiveCharacterTextSplitter και επιστρέφει μια λίστα ,με τα chunks που προέκυψαν από το άρθρο, την οποία και προσθέτουμε/ενώνουμε με τη λίστα που δημιουργήσαμε αρχικά.

```
chunks = [] #Pinakas gia ta chunks
for article in articles:
    chunks.extend(text_splitter.split_text(article)) #Prosthetoume ta chunks pou mas dinei o text_splitter
```

Στη συνέχεια, κρατάμε σε μια μεταβλητή device το οποίο παίρνει την τιμή "cuda" ή cpu ανάλογα με το αν υπάρχει διαθέσιμη gpu που υποστηρίζει cuda ή όχι. Με αυτό τον τρόπο δίνουμε στο χρήστη τη δυνατότητα στη συνέχεια όπου και θα χρειαστεί να δημιουργηθούν τα embeddings για το κάθε chunk, να χρησιμοποιήσει την κάρτα γραφικών του για να κερδίσει χρόνο (περισσότερα στη συνέχεια).

```
device = "cuda" if torch.cuda.is_available() else "cpu"
print("Using device:", device) #DEBUGGING
```

Σε αυτό το σημείο θέτουμε το μοντέλο που θα δημιουργήσει τα επιμέρους διανύσματα (embeddings). Συγκεκριμένα, από την βιβλιοθήκη sentence_transformers χρησιμοποιούμε τη μέθοδο SentenceTransformer και της περνάμε ως όρισμα το μοντέλο all-MiniLM-L6-v2 και το device με το οποίο θα το χρησιμοποιήσουμε. Το μοντέλο αυτό, μετατρέπει τα chunks σε διανύσματα σταθερού μεγέθους των 384 διαστάσεων. Επίσης, το συγκεκριμένο μοντέλο μπορεί εκτός από cpu να χρησιμοποιηθεί και με τη χρήση gpu μέσω του pytorch. Έτσι, στη συνέχεια καλούμε τη συνάρτηση encode του model για τα chunks που έχουμε δημιουργήσει πιο πριν. Επειδή λοιπόν αυτό που μας επιστρέφεται είναι ένας NumPy πίνακας όπου το μηδενικό στοιχείο είναι ο αριθμός των embeddings που έχουμε και το πρώτο στοιχείο είναι ο αριθμός των διαστάσεων αυτών. Έτσι, κρατάμε στην μεταβλητή dimension τη διάσταση των embeddings καθώς θα μας χρειαστεί στη συνέχεια.

```
model = SentenceTransformer('all-MiniLM-L6-v2', device=device)
embeddings = model.encode(chunks, show_progress_bar=True)
dimension = embeddings.shape[1]
```

Κάτι που πιστεύουμε αξίζει να σημειωθεί είναι η διαφορά στον χρόνο δημιουργίας των embeddings με gpu και με cpu. Συγκεκριμένα, τρέξαμε την συνάρτηση σε pc που δεν υποστηρίζει cuda και ο χρόνος που χρειάστηκε για την δημιουργία των

διανυσμάτων ήταν περίπου μισή ώρα. Αντίθετα, σε pc που υποστήριζε cuda και συγκεκριμένα με κάρτα γραφικών GTX1650Ti και cuda 11.8 ο χρόνος που χρειάστηκε ήταν μόλις 2 λεπτά. Για αυτό στο github repository περιλαμβάνουμε εξ 'αρχής τα αρχεία chunk_metadata.csv και articles_index.faiss ώστε σε περίπτωση που ο υπολογιστής του χρήστη δεν υποστηρίζει cuda να μπορεί να τα περάσει απευθείας.

Προχωρώντας, φτάνουμε σε ένα σημαντικό σημείο όπου, ορίζουμε το λεξικό που θα αποθηκευτούν τα embeddings. Θα χρησιμοποιήσουμε ένα FAISS λεξικό και συγκεκριμένα αυτό που χρησιμοποιεί την ευκλείδεια απόσταση(FlatL2) για να συγκρίνει την απόσταση μεταξύ των διανυσμάτων, δηλαδή το similarity τους. Αυτό θα μας χρειαστεί στη συνέχεια όταν θα πρέπει να συγκρίνουμε το similarity του διανύσματος του query με τα διανύσματα που θα έχουμε αποθηκευμένα στο index, ώστε να παίρνουμε τα πιο σχετικά αποτελέσματα. Για να χρησιμοποιήσουμε τη συνάρτηση faiss. IndexFlatL2 θα χρειαστούμε την βιβλιοθήκη faiss. Περνάμε ως όρισμα στην συνάρτηση τη διάσταση των διανυσμάτων ώστε το index να είναι τέτοιο μεγέθους και το κρατάμε στην ομώνυμη μεταβλητή. Προσθέτουμε σε αυτό τα embeddings και το γράφουμε σε αρχείο.

```
index = faiss.IndexFlatL2(dimension)
index.add(np.array(embeddings))
faiss.write_index(index, INDEX_FILE)
```

Τέλος, δημιουργούμε ένα dataframe που θα περιέχει μια στήλη στην οποία θα υπάρχουν όλα τα chunks. Τέλος μετατρέπουμε το dataframe σε csv αρχείο.

```
chunk_metadata = pd.DataFrame({"chunk": chunks})
chunk_metadata.to_csv(CHUNKS_FILE, index=False)
```

query_engine.py

Στο παρόν σημείο της εργασίας θα αναλύσουμε το αρχείο query_engine.py στο οποίο υλοποιούμε τις συναρτήσεις για την δημιουργία του prompt καθώς και για την δημιουργία της απάντησης που θα πάρουμε από το LLM.

Όπως και πριν, ξεκινάμε με το να κάνουμε import τις απαραίτητες βιβλιοθήκες που θα μας χρειαστούν στη συνέχεια.

```
import faiss
import pandas as pd
import numpy as np
from sentence_transformers import SentenceTransformer
from ollama import Client
```

Επειτα, ορίζουμε και πάλι κάποιες σταθερές όπου κρατάμε το όνομα του index, του csv αρχείου που περιέχει τα chunks και το μοντέλο που θα χρησιμοποιήσουμε για τον υπολογισμό των embeddings (όπως και πριν χρησιμοποιούμε το all-MiniLM-L6-v2). Επιπλέον, δημιουργούμε την σταθερά client όπου είναι αυτή που θα κρατάει το local host του ollama. Η συνάρτηση *Client* προέρχεται από το ollama package, το οποίο επιτρέπει την επικοινωνία με τον ollama server που τρέχει locally στο pc μας. Το

ollama κατά την εκτέλεση του, ξεκινάει έναν local server στο port 11434 και έτσι καλώντας την Client δημιουργούμε ένα αντικείμενο που μπορεί να στείλει requests με prompts και να πάρει responses από το μοντέλο.

```
INDEX_FILE = "articles_index.faiss"
CHUNKS_FILE = "chunk_metadata.csv"
embedding_model = SentenceTransformer('all-MiniLM-L6-v2')
client = Client(host='http://localhost:11434')
```

Η πρώτη συνάρτηση που θα υλοποιήσουμε στο αρχείο είναι η build_prompt. Η συνάρτηση είναι πολύ απλή και ουσιαστικά ο σκοπός της είναι η δημιουργία ενός δομημένου prompt με βάση το query του χρήστη και των chunks που θα έχουν βρεθεί προηγουμένως και τα οποία θα χρησιμοποιηθούν ως context. Κρατάμε ως context την ένωση όλων των chunks που έχουμε ανακτήσει και απλά επιστρέφουμε το prompt που μας προτάθηκε από την εκφώνηση της άσκησης.

Στη συνέχεια, υλοποιούμε την συνάρτηση answer_query. Η συνάρτηση αυτή, είναι στην ουσία μια μηχανή ερωτήσεων-απαντήσεων η οποία παίρνει το query του χρήστη και χρησιμοποιώντας το LLM που έχουμε επιλέξει (στη περίπτωση μας το llama3.2:3b) δίνει ένα response με βάση τα 5 πιο relevant chunks σε σχέση με το query του χρήστη. Αρχικά, διαβάζουμε το faiss index και το csv αρχείο με τα chunks. Δημιουργούμε το embedding του query του χρήστη, με τον ίδιο τρόπο που δημιουργούσαμε τα embeddings των chunks που προσθέσαμε στο faiss index. Το διάνυσμα του query που θα πάρουμε έχει την ίδια διάσταση και με τα διανύσματα των chunks που βρίσκονται στο faiss index έτσι ώστε να μπορούν να συγκριθούν με αυτά. Η σύγκριση γίνεται στην επόμενη εντολή όπου και γίνεται το search στο index. Συγκεκριμένα, πάνω στο index καλούμε την συνάρτηση search της βιβλιοθήκης faiss, η οποία δέχεται ως όρισμα έναν NumPy πίνακα (εξού και η μετατροπή του query_embedding σε ηρ. αιταγ) και τον αριθμός που καθορίζει πόσους κοντινούς γείτονες να επιστρέψει για κάθε διάνυσμα αναζήτησης (στην περίπτωση μας επιλέξαμε τα 5 κοντινότερα).

```
def answer_query(user_query, model_name="llama3.2:3b", k=5):
    index = faiss.read_index(INDEX_FILE)
    chunks_df = pd.read_csv(CHUNKS_FILE)

    query_embedding = embedding_model.encode([user_query])
    distances, indices = index.search(np.array(query_embedding), k)
    top_chunks = [chunks_df.iloc[idx]["chunk"] for idx in indices[0]]
    prompt = build_prompt(user_query, top_chunks)

    response = client.generate(model=model_name, prompt=prompt)
    return response['response'].strip(), top_chunks
```

Αυτά που επιστρέφει η search είναι έναν πίνακα με τις αποστάσεις το k κοντινότερων διανυσμάτων από το query και έναν πίνακα με τα indices αυτών των διανυσμάτων στο faiss index. Στην υλοποίηση μας αυτό που θα μας χρειαστεί είναι το δεύτερο. Έπειτα, κάνοντας ένα list comprehension διατρέχουμε το dataframe των chunks (chunks df.iloc[idx]["chunk"] for idx) και κρατάμε τα chunks που βρίσκονται στις θέσεις που μας δείχνει ο πίνακας indices (in indices[0]). Ουσιαστικά, έχοντας κρατήσει τις θέσεις των k-relevant chunks στον πίνακα indices (σε μορφή διανυσμάτων πριν στο faiss index) απλά πηγαίνουμε στις αντίστοιχες γραμμές του data frame με μοναδική στήλη "chunk" και κρατάμε στην λίστα top chunks τα πιο σχετικά με την ερώτηση chunks. Κρατάμε ακόμα το prompt στην ομώνυμη μεταβλητή, καλώντας απλά την built prompt και δίνοντας της ως ορίσματα το query και τα top chunks που ανακτήσαμε πριν. Χρησιμοποιώντας το instance client που ορίσαμε στην αργή, καλούμε το LLM (llama3.2:3b) που τρέγει τοπικά μέσω του ollama server και του δίνουμε το prompt που έχουμε φτιάξει. Αυτό που θα μας επιστραφεί είναι ένα λεξικό όπου ο πρώτος της όρος είναι το "response': response string'". Για αυτό και στην τελευταία γραμμή επιστρέφουμε το περιεχόμενο του πεδίου response (response [response].strip()) καθώς και τα top chunks. Όσον αφορά του LLM, όπως αναφέρθηκε και προηγουμένως, επιλέξαμε το llama3.2:3b αντί του llama3.2:1b καθώς μετά από μια σύντομη έρευνα καταλήξαμε ότι είναι πιο ικανό για μεγαλύτερα project όπως πχ η υλοποίηση μιας RAG αρχιτεκτονικής. Συγκεκριμένα, η κύρια διαφορά μεταξύ τους βρίσκεται στις παραμέτρους όπου μπορεί να δεχτεί το εκάστοτε μοντέλο, όπου το llama3.2:3b δέχεται 3 billion parameters ενώ το llama3.2:1b δέχεται 1 billion. Όσον αφορά τον τεχνικό τομέα, το μοντέλο που επιλέξαμε έχει μεγαλύτερη κατανάλωση πόρων, ωστόσο θεωρήσαμε ότι είναι ένα καλό tradeoff για την αυξημένη απόδοση που θα παίρναμε σε σχέση με το άλλο μοντέλο.

gui app.py

Το gui_app.py είναι το αρχείο του προγράμματος που περιέχει το main πρόγραμμα. Είναι υπεύθυνο για την κλήση των κατάλληλων συναρτήσεων κατά την εκτέλεσή του και προσφέρει το γραφικό περιβάλλον στον χρήστη.

Το main πρόγραμμα ελέγχει αν εκτελέστηκε απευθείας ώστε να καλέσει την launch_gui() συνάρτηση η οποία δημιουργεί το γραφικό περιβάλλον και θέτει ποιες λειτουργίες θα εκτελεστούν αν πατηθεί το "submit" πλήκτρο ή το "enter" πλήκτρο από το πληκτρολόγιο.

```
def launch gui():
   global root, entry, text_output, submit_button
   root = Tk()
   root.title("RAG AI Assistant")
   root.geometry("700x500")
   Label(root, text="Enter your prompt:", font=("Arial", 12)).pack(pady=5)
   entry = Entry(root, width=80)
   entry.pack(pady=5)
   entry.bind("<Return>", process_query)
   submit_button = Button(root, text="Submit", command=process_query)
   submit_button.pack(pady=5)
   scrollbar = Scrollbar(root, orient=VERTICAL)
   scrollbar.pack(side=RIGHT, fill=Y)
   text_output = Text(root, wrap="word", yscrollcommand=scrollbar.set)
   text_output.pack(expand=True, fill="both")
   scrollbar.config(command=text_output.yview)
```

Επίσης στην ίδια συνάρτηση γίνεται το initialization των αρχείων τα οποία θα χρησιμοποιηθούν αργότερα για να μπορεί να βγάλει αποτέλεσμα το μοντέλο. Αν υπάρχουν τα αρχεία αυτά τότε δεν τα δημιουργεί ξανά.

```
if not os.path.exists(INDEX_FILE) or not os.path.exists(CHUNKS_FILE):
    initialize_data()
else:
    text_output.insert(END, "Data already initialized. Enter your prompt.\n")
```

Η συνάρτηση initialize_data απενεργοποιεί το πλήκτρο "submit" και καλεί με την συνάρτηση Thread() την run_init() ώστε να μην μπλοκάρει το πρόγραμμα κατά την διάρκεια αυτής της διαδικασίας. Η run_init() καλεί την generate_faiss_and_chunks() την οποία αναφέραμε νωρίτερα.

Τέλος η το πλήκτρο "submit" όπως και το "enter" καλούν την συνάρτηση process query η οποία καλεί την run query() με την χρήση Thread() συνάρτησης

ώστε να μην μπλοκάρει το πρόγραμμα. Η run_query() καλεί με την σειρά της την answer_query() ώστε να πάρει το αποτέλεσμα από το ερώτημα του χρήστη και το εμφανίζει.

```
def run_query(query):
        response, used_chunks = answer_query(query)
        def update_ui():
           text_output.delete("1.0", END)
text_output.insert(END, "➤ Response:\n")
            text_output.insert(END, response)
            text_output.insert(END, "\n\n➤ Relevant chunks:\n")
            for i, chunk in enumerate(used_chunks, start=1):
               text_output.insert(END, f"\n[{i}] {chunk}\n")
            submit_button.config(state=NORMAL)
            entry.config(state=NORMAL)
            entry.delete(0, END)
            entry.focus()
        root.after(0, update_ui)
        def show_error():
           text_output.insert(END, f"\nError:\n{str(e)}")
            submit_button.config(state=NORMAL)
        root.after(0, show_error)
def process_query(event=None):
   query = entry.get().strip()
   if not query:
   text_output.delete("1.0", END)
text_output.insert(END, "Searching...\n")
   submit_button.config(state=DISABLED)
   entry.config(state=DISABLED)
   threading.Thread(target=run_query, args=(query,), daemon=True).start(
```

Πειραματικές δοκιμές

Στο τελευταίο σημείο της παρούσας εργασίας, θα κάνουμε κάποιες δοκιμές όπως μας ζητήθηκε από την εκφώνηση της άσκησης. Συγκεκριμένα, θα εκτελέσουμε 5 queries και στη συνέχεια θα παραθέσουμε τα αποτελέσματα που θα μας δώσει το μοντέλο με και χωρίς το context.

"What is Covid?"

Mε context

	Ernet your prompt.	
ĪV.	What is covid?	
	Submit	
> Response: COVID-19, also known as coronavirus disease 2019, is a respiratory global pandemic.	illness caused by the SARS-CoV-2 virus. It was first identif	ified in Wuhan, China in December 2019 and has since become a
The COVID-19 virus is a member of the coronavirus family, which in an animal source, possibly bats, and was transmitted to humans thro		
The COVID-19 virus attacks the lungs and airways, causing inflammat	tion and damage to these tissues. This can lead to symptoms	such as:
* Fare: COugh * Shortness of breath * Fatigue * Headache * Sore throat		
In severe cases, COVID-19 can cause pneumonia, acute respiratory d:	istress syndrome (ARDS), and even death.	
The spread of COVID-19 is often facilitated by close contact with	an infected person, such as through:	
* Respiratory droplets that are released when an infected person to * Close contact with an infected person's skin or eyes * Touching contaminated surfaces and then touching one's face	alks, coughs, or sneezes	
To prevent the spread of COVID-19, public health officials recommen	nd practices such as:	
* Frequent handwashing with soap and water * Wearing a mask in public places * Seaying at least 6 feet swy from others * Avoiding close contact with people who are sick * Getting waccinated against COVID-19 * Getting wac		
Vaccines have been developed to prevent severe illness and hospital	lization due to COVID-19. These vaccines have been shown to	be highly effective in preventing the spread of the virus.
Overall, COVID-19 is a serious public health threat that requires	continued vigilance and cooperation to prevent its spread.	

Χωρίς context

"Tell me some facts about Wimbledon"

Enter your prompt:
Tell me some facts about Wimbledon
Submit
➤ Response:
Here are some facts about Wimbledon:
l. It's one of four Grand Slam tennis tournaments, along with the Australian Open, French Open, and US Open.
2. The tournament is held at the All England Lawn Tennis Club in London. S. Wimbledon in the only Grand Slam event still played on grass.
4. Roger Federer holds the record for most singles wins (male) with eight victories.
5. Martina Navratilova holds the record for most singles wins (female) with nine victories. 6. The oldest winner of the Men's Singles sitle is Rooer Federer, who won in 2017 at the age of 35.
7. Wimbledon was suspended during World War I and World War II.
8. A bomb hit Centre Court in 1940, resulting in the loss of 1,200 seats.
9. Female winners received equal cash awards for the first time in 2007. 10. The retractable roof over Centre Court was unveiled in 2009.
11. Wimbledon is no longer held during the summer due to the COVID-19 pandemic, but it returned in 2022.
Additionally, I found some interesting facts about this year's tournament:
* It was the first time a Romanian player won the tournament. * Australian top seed Dylan Alcott completed a golden slam by winning both singles and wheelchair events.
> Relevant chunks:
[1] also the first Romanian to win the tournament. Other FactsWimbledon is one of four Grand Slam tennis tournaments. The others are the Australian Open, the French Open and the US Open.Wimbledon takes place at the All England Lawn Tennis Club in London. Wimbledon is the only Grand Slam event that is still played on grass.RecordsMost singles wins (male) - Roger Federer with eight.Most singles wins (meale) - Martian Reverticew with nine. Cludes to inner (male) - Roger Federer won the Men's Singles
[2] the year before his first championship there.*I noticed the mishits, awkward looking points from Roger and obviously the last set of course, 6-0,* three-time Wimbledon champion Boris Becker told the BBC.This was Federer's first straight sets loss at Wimbledon since 2002 when he was beaten by Mario Ancic in the first round.
[3] is suspended during World War I.1922 - The Championships move to Church Road, Wimbledon's current location.1940-1945 - Wimbledon is suspended during World War II.October 1940 - During WMII, a bomb hits Centre Court, which results in the loss of 1,200 seats in the stadium.2007 - Female winners receive the same cash awards as the male winners for the first time.May 17, 2009 - The retractable roof over Centre Court is unveiled during an exhibition match.October 2018 - The The All England Lawn
[4] this month. "For a long time it wasn't possible because Mimbledon didn't have a singles event. For a few years now they've had it it's just great to see the tour and the professionalism going up each year, "Be Groot told reporters," To be the first one to actually get that title is just so special. I don't think I will ever forget that. "Not long after on Sunday, Australian top seed Dylam Alcott also completed a golden slam in his respective event, taking down Dischmann Nicle Vink 7-5 6-2 in the
[5] infectious around the time of the event and the rest likely to have acquired an infection then. The Wimbledon tennis championships, with around 300,000 people attending over the two weeks, recorded 881 cases. "We've shown that we can reintroduce mass sports and cultural events safely but it is important that people remain cautious when mixing in very crowded settings," said Culture Minister Cityer Dowden. "So that we can keep the football season, theaters and gips safe with full crowds this full crowds this

	Enter your prompt:	
Tell me some facts a	about Wimbledon	
	Submit	
➤ Response:		
Wimbledon! Here are some fascinating facts about one of the most prestigious te	nnis tournaments in the world:	
1. "*Oldest Tennis Tournament": Wimbledon is the oldest tennis tournament in t who patented the first netted tennis court.	the world, with a rich history dating back to	1877. It was founded by Walter Clopton Wingfield, an Englishman
 Grass Courts: Wimbledon is still known for its iconic grass courts, whice \$100,000 per week on maintaining the grounds. 	th are maintained to perfection every year. Th	e All England Lawn Tennis and Croquet Club (AELTC) spends over
 The White Suit Tradition: Men's tennis players have traditionally worn w fashion statements in sports. 	white suits at Wimbledon since 1884. This trad	lition is still observed today, making it one of the most iconic
 Royal Connection: The tournament has a long history of royal connections **Komen's Tennis Pioneer**: In 1884, Maud Watson became the first woman to w of women's tennis players. 		
6. **The Championships Name**: The official name of the tournament is "The Cham 7. **Record Attendance**: In 2019, Wimbledon set an all-time record attendance		
8. **Unique Ball Boys/Girls**: Wimbledon is one of the few tennis tournaments t days of tennis.	that still employs ball boys and girls to retr	ieve balls during matches. This tradition dates back to the early
9. **The Straw Hat Tradition**: In the 1970s, British players began wearing str tournament's charm.	aw hats on court as a symbol of their nationa	l heritage. Today, it's a quirky tradition that adds to the
10. **A True Test of Endurance**: Wimbledon is known for its physically demandi	ing nature, with players often suffering from	fatigue and injury during the five-day competition.

Χωρίς context

"Tell me about Tom Felton"

	Enter your prompt:	
Tell me ab	out Tom Felton	
	Submit	
Response: ased on the context, here's what I know about Tom Felton;		
om Felton is a British actor, musician, and golfer. He is best known for	playing the role of Draco Malfoy in the Harry Potte	r film franchise. He was born on September 22, 1987.

These facts showcase the rich history, traditions, and unique aspects of Wimbledon, making it one of the most beloved tennis tournaments in the world.

Recently, he experienced a medical incident while participating in a celebrity golf match at Whistling Straits, Misconsin, ahead of the Ryder Cup. He collapsed on the course and was carted off for treatment, but was conn

Additionally, Tom Telton's personal life was mentioned in a separate context, where Tom Brady Sr., the father of NFL quarterback Tom Brady, discussed how he struggled with alcoholism during Tom DeBlass' childhood.

[3] dited the 44-year-old quarterback as "a special person and the greatest quarterback of all-time" upon his departure. Speaking ahead of the week four fixture on Tom Curran's Patriots Talk podosas, Essdy's father, Tom Essdy Spr., discussed his son's exit from the team he spent two decodes with. "My feeling is Tomay in extremely appreciative of everything that happened during his Mew Depland career and he's more than happy thath he's moved on because it was pretty obvious that the fourtine regime fell."

[4] kind. His voice would raise, and he wasn't affectionate and then I realized there was something ... not smooth. Read More'I really didn't comprehend at that time what alcoholism was, but I understood something wasn't normal. Tom Dellass with his father, Tom Dellass Sr.His father's alcohol and drug addiction was a recurring theme throughout Dellass' childhood. On the day he was born, Dellass says the police had to be couled to his house to 'tip me out of my father's hands' because he was so

[5] be exceptionally honored, according to a Downing Street press release at the time. "Colonel Tom's fantastic fundraising broke records, inspired the whole country and provided us all with a beacom of light through the fog of coronavirus," Johnson said in the release.

Mε context

	Enter your prompt:	
	Tell me about Tom Felton	
	Submit	
> Response: Tom Felton is a British actor, musician, and social media persona.	ality. He was born on September 22, 1987, in Kensington, London	n, England.
Felton is best known for his iconic role as Draco Malfoy in the H household name among fans of the series.	Marry Potter film franchise, based on the book series by J.K.	Rowling. He played the character from 2000 to 2011 and became a
Apart from acting, Felton has pursued other interests, such as mu	sic. In 2016, he released his debut single "Wonderful World,"	followed by an album called "A Different Song" in 2022.
Felton has been open about his struggles with anxiety and depress LGSTQ+ rights and has supported various charitable organizations		around mental health issues. He is also a vocal advocate for
In addition to acting and music, Felton has become increasingly personal growth. His down-to-earth personality and witty humor has		e, where he shares his thoughts on life, creativity, and
Felton has continued to work in film and television, including ro	oles in "The Flash," a CW series based on the DC Comics charact	ter, and "Origin," a 2020 sci-fi thriller film.
Throughout his career, Tom Felton has demonstrated his range as a	n actor and musician, while also building a loyal fan base ac	ross various platforms.

Χωρίς context

"Tell me about London's statues"

Enter your prompt:
Tell me about London's statues
Submit
De Desconaer

- "*Low representation of women": Only 4% of public sculptures in London depict women, while a staggering 8% represent animals and just 1% represent people of color.
 "*Highest percentage dedicated to women among UK cities": Despite this, London has the highest percentage of sculptures dedicated to women compared to other major UK cities.
 "*Gupen 'Uncortal as the most represented woman': Queen Victoria as the most represented woman': Queen Victoria is the most reflected woman in London's satues, reflecting her long and influential reign from 1815-1901.
 "*Inadequate representation of underrepresented groups": The study found that people of color account for just 1% of the city's sculptures, with women of color making up an even smaller "..."

[1] data on London's sculptures since 2017 as part of a major research project, which is funded in part by City Hall. Among the UK's largest cities, London has the highest percentage of sculptures dedicated to women. Why the tappled status of slave trader Edward Colston is going on public display in EnjandMationetde, Queen Victoria, who reigned from 1819 -- 1901, is the most represented woman. Hany of Britain's moments have faced a rectoning surve global protects against systemic racism and

Me context

Enter your prompt:
Tell me about London's statues
Submit
Response:
ndon, the capital city of England, is renowned for its rich history and cultural heritage, which is reflected in its numerous iconic statues. Here are some of the most notable ones:
"The Dike of Mellington": Located in St. Smeet's Ruck, this status commencates the victory of British forces over Mapoleon at the Battle of Materileo in 1815. The statue features needal Action Mellesley (later known as the Dake of Mellington) riding a hosten.
"Abraham Lincoln": Strusted in Trafalgar Square, this statue was a gift from the American specule to honor the 16th President of the United States. Designed by sculptor Daniel Chester ench. it features Lincoln stuting in contemplation, holding his famous too hat and wearing his local square studies and the United States. Designed by sculptor Daniel Chester ench. it features Lincoln stuting in contemplation, holding his famous too hat and wearing his people specified by
"Queen Elizabeth II": Located in Whitehall Gardens, this statue celebrates the reign of Queen Elizabeth II (1926-2022). The sculpture was designed by sculptor Thomas Woolner and ppicts the Queen standing majerically with her hands on a clobe.
I'van the Terrible! Situated in Trafalgar Square, this imposing bronze statue is one of the most famous works by artist Ivan Kulibin. It depicts Ivan III (also known as Ivan the east) holding an axe and weating traditional Russian armor.
"'Minston Churchill'": Located in Parliament Square, this statue was designed by sculptor Ivor Roberts-Watts and features Churchill standing tall with his cigar and arm outstretched. "'Lord Melson": Struated on Trafalgar Square's loonic column, this statue honors the British naval hero Horatio Helson, who won a decisive victory over Napoleon at the Battle of afaloar in 1802.
"'Charlee Dickens": Located in Covenc Gardem, this status was designed by sculptor Sir Francis Galton and features the famous author sitting on a bench, surrounded by books. ""William Shakespeare": Situated in Stratford-upon-Avon (not London), but often associated with the city, there is no official London status dedicated to the Bard. However, there are retained tributes and monuments throughout the city.
ese statues showcase London's rich history, cultural heritage, and iconic figures who have shaped the city's identity.
uld you like me to tell you more about any specific statue or location?

Χωρίς context

"Tell me about Germany"

Enter your prompt:	
Tell me about Germany	
Submit	

Okav. let me try to stay on topic and provide some general information about Germany:

Germany is a federal parliamentary republic located in Central Europe. It is the largest economy in Europe, the fourth-largest in the world, and has a population of around 83 million people (although the article mentions 60.4 million eligible to vote, which is likely due to EU voting regulations).

Germany is known for its rich history, culture, and contributions to science, technology, engineering, arts, and mathematics (STEAM). The country has produced famous philosophers like Immanuel Kant, Johann Wolfgang von Goethe, and Friedrich Nietzsche, as well as influential scientists like Albert Einstein.

German cuisine is famous for its sausages, beer, bread, and pastries. Some popular dishes include schnitzel, sauerbraten, and spätzle. The country is also known for its vibrant music scene, with genres like techno, house, and classical music originating from Germany.

Germany has a strong economy, with major industries like automotive (Volkswagem, Mercedes-Benz), aerospace (Airbus), and renewable energy (solar, wind power). Berlin is the capital city, and Munich is the largest city in Bavaria. The country has a well-developed public transportation system and is known for its efficient autobahn network.

Germany's history is complex and tumultuous, having experienced two devastating World Wars, as well as the Holocaust during WWII. However, the country has made significant efforts to come to terms with its past and promote reconciliation.

[2] Foland over their adherence to the EU's rule of law.'We can manage this'There were also times when Herkel didn't go looking for a compromise, most notably in 2015 when she welcomed refugees fleeing conflicts in Syria and elsewhere. "Folitically persecuted people have the right to asylum. We can be proud of the humanity of our Basic Law ... we also grant protection to all those who flee to us from wars," she told the German people that summer. "I put it simply German's a strong country. The

[5] big thing. It's a real shame that there won't be as many German supporters in the ground because of the Covid restrictions. Wembley is (the very best) for German football fans," he adds. There are still those, mainly from the English tabloid press, who have looked to find unhealthy links between the football rivalry and the two countries" political past, including the two World Mars. But the majority see it for what it really is: two footballing powerhouses, guadas packed with talent and a

Enter your prompt:
Tell me about Germany
Submit
Response: Germany is a federal parliamentary republic located in Central Europe, bordered by Denmark, Foland, Czech Republic, Austria, Switzerland, France, Belgium, and the Netherlands. With a population of approximately 83 million people, it is the most populous country in the European Union.
Geography and Climate:
Germany's terrain is varied, with mountains, forests, and plains covering about 60% of its land area. The Alps cover the southeastern part of the country, while the North Sea and Baltic Se border Germany to the north. The climate ranges from temperate maritime in the northwest to continental in the southeast.
History:
Germany has a rich and complex history, with many empires rising and falling over the centuries. The Holy Roman Empire (10th-19th century) was a loose confederation of states that eventually fragmented into modern-day Germany. The unification of Germany under Otto von Bismarck's leadership in 1871 marked the beginning of a new era. However, this period also saw two devastating world wars, including Mocil Mar I and Mocil War II.
Economy:
Germany is one of the world's leading economies, with a strong focus on innovation, quality, and sustainability. The country has a highly developed manufacturing sector, particularly in that automotive and engineering industries. Germany is also home to many world-renowned companies like Mercedes-Senz, BMS, and Siemens.
Culture:
German culture is known for its rich heritage, vibrant arts scene, and unique festivals. Oktoberfest, a famous beer festival held annually in Munich, attracts millions of visitors worldwide. Germany has produced influential artists like Bach, Beethoven, and Wagner, as well as loconic writers like Goethe and Mann.
Places to Visit:
Some popular destinations in Germany include:
l. Berlin: The capital city is known for its vibrant arts scene, historic landmarks like the Brandenburg Gate, and museums like the Fergamon Museum. 2. Munich: Famous for Oktoberfest and home to the loonic Newschwansetan Castle, a fairytale-like palace built by King Ludwig II. 3. Hamburg; A major port city with a rich maritime history, colorful buildings, and vibrant nightline without nightline in the state of the s
Cuisine:
Traditional German dishes include sausages (e.g., Bratwurst), schnitzel, sauerbraten, potato dumplings (Kartoffelpüree), and apple strudel. Germany is also famous for its beer culture, wit many breweries offering tours and tastings.
Language:
The official language of Germany is German (Deutsch), but many people also speak English, especially in tourist areas.

Χωρίς context

Το συμπέρασμα στο οποίο καταλήγουμε, είναι ότι σε περιπτώσεις όπου η αναζήτηση αναφέρεται σε ένα πολύ συγκεκριμένο θέμα ή πρόσωπο, πχ "Tell me some facts about Wimbledon" ή "Tell me some facts about Tom Felton" η RAG αρχιτεκτονική βοηθάει πολύ στο να έχουμε πιο στοχευμένες απαντήσεις επάνω στο θέμα. Σε ερωτήσεις γενικότερης κλίμακας οι απαντήσεις είναι και πάλι πολύ εύστοχες και σίγουρα βοηθάει και πάλι η αρχιτεκτονική RAG, οι διαφορές όμως με context και χωρίς είναι λιγότερο αισθητές.